Pruning ResNet

Strukturalny pruning na Chest X-ray

Temat

Structured pruning w klasyfikacji obrazów medycznych.

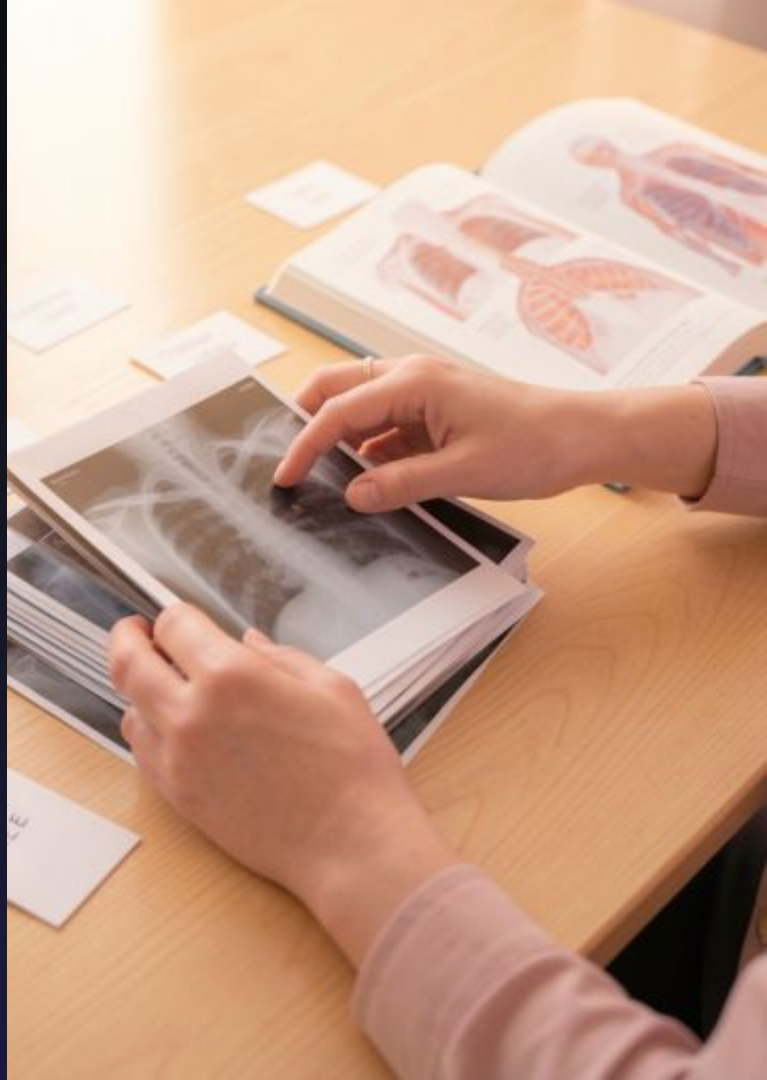
- L1-norm pruning
- Network Slimming
- Taylor pruning



Dane i ograniczenia

W wstępnej fazie 1 użyto próbki NIH ChestX-ray14: 5606 obrazów zamiast pełnych 112k;

- 14 etykiet chorób binarnych;
- duża nierównowaga klas, np. bardzo mało przypadków Hernia i Pneumonia (użyto
- augmentacja tylko na treningu (horizontal flip, mała rotacja)
- dla niezbalansowanych klas zastosowano pos_weight w BCEWithLogitsLoss



Baseline i metryki

Baseline test: ResNet-34 (pretrained on ImageNet), AUC **0.7277** , F1 macro 0.1712, Sensitivity 0.4317.
Model: 21.29M parametrów, 3.68G MACs.

Na tym etapie model był niedotrenowany (krótkie epoki, mały zbiór), AUC przyzwoite, niskie f1 i sensitivity - dużo false negativeów.

Wyniki porównawcze

Porównanie (30% pruningu):

Baseline AUC 0.7277;

L1 AUC 0.7211, Params 10.41M - **najlepszy trade -off**.

Network Slimming AUC 0.6859, Params 5.07M - największa kompresja, największy spadek.

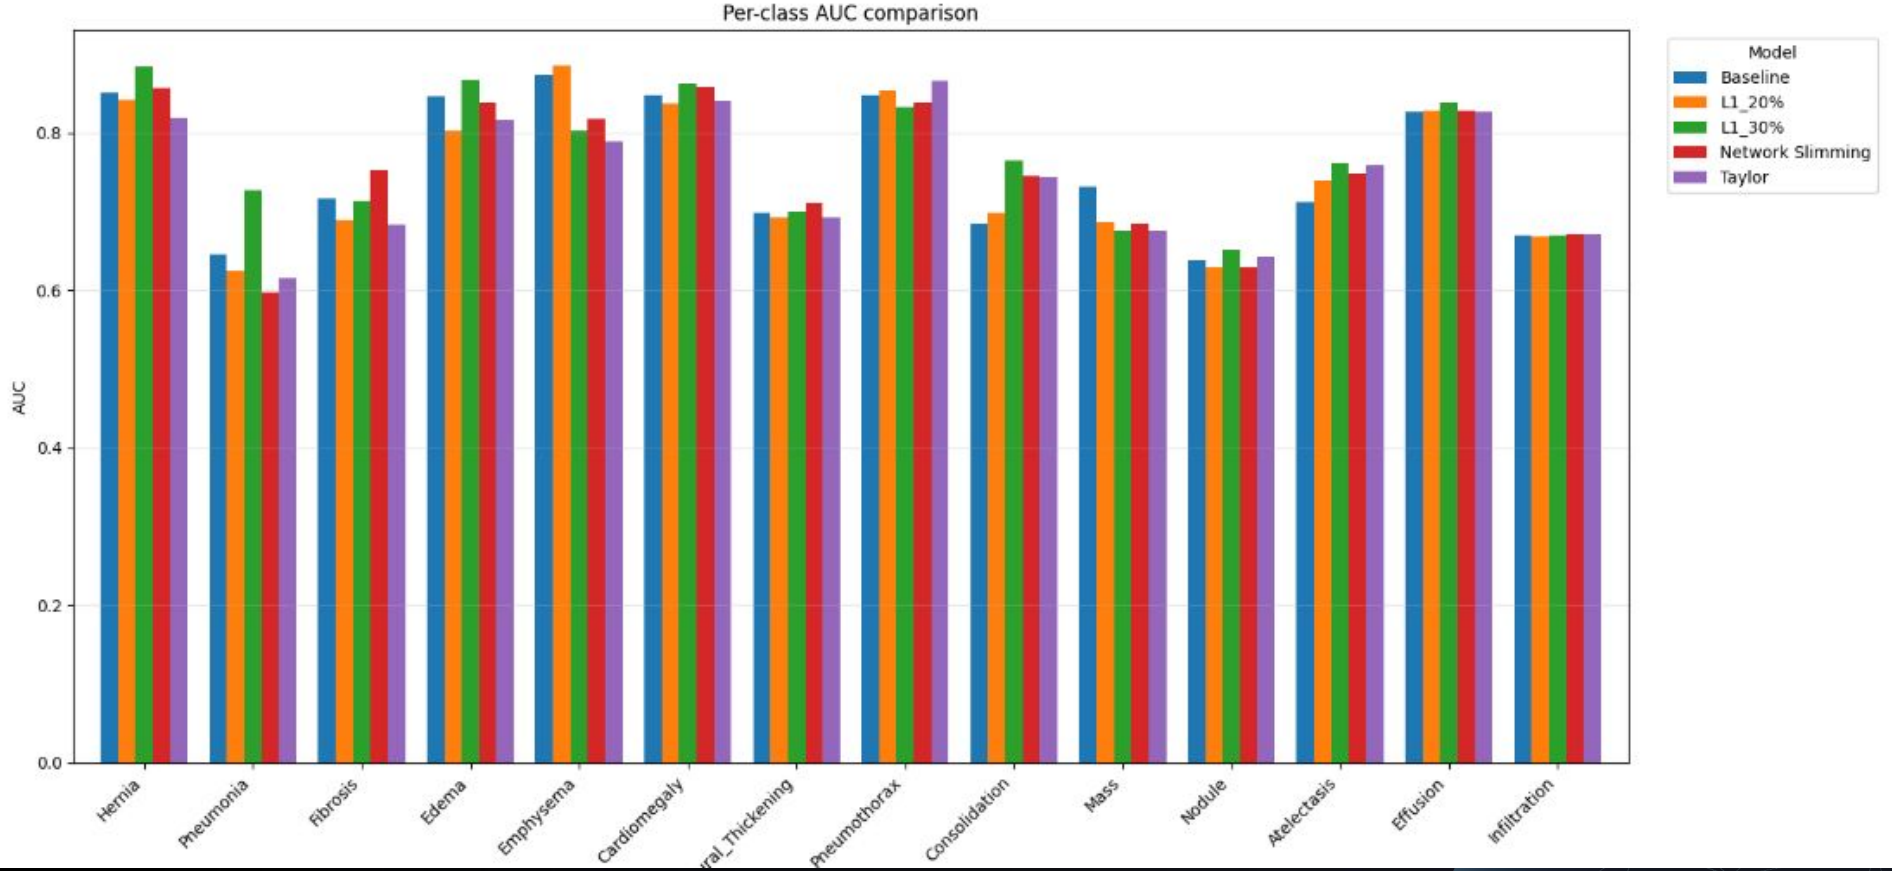
Taylor AUC 0.6987 - rozczarowujący wynik przy podobnej kompresji.

Skalowanie Eksperymentów

- 20 000 obrazów z patient-level split
- grid search dla Network Slimming
- L1 Pruning przy ekstremalnych współczynnikach (80% i 90%)

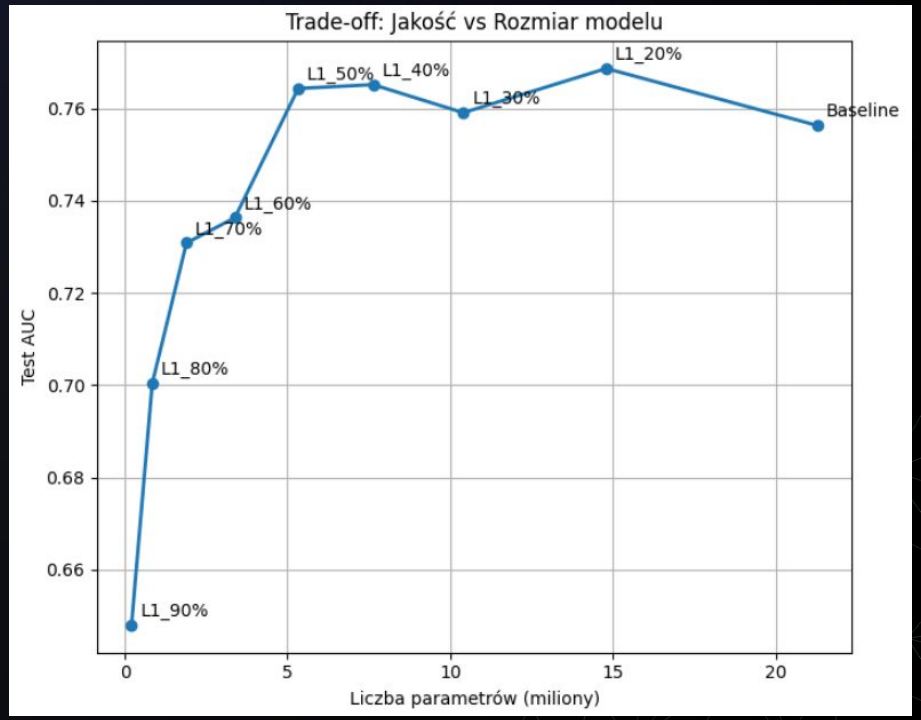
dla Network Slimming zestaw BN_L1_LAMBDA=0.002, 35% pruning okazał się najlepszym, AUC = 0.7604 przy ~8.96M parametrów

dobry wynik uzyskałam również dla Taylor pruning (~0.77).

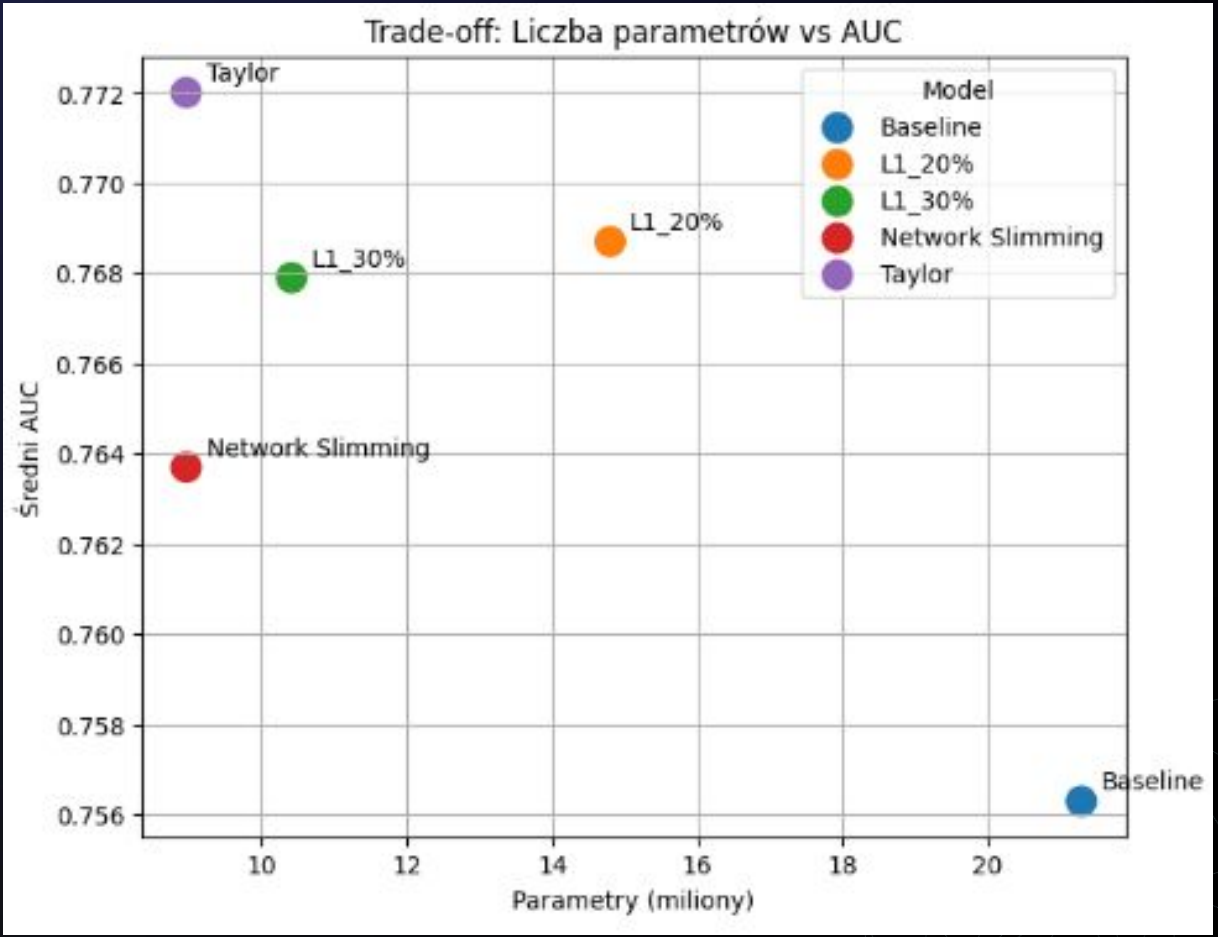

Per-class AUC comparison
AUC
0.0
0.2
0.4
0.6
0.8
Model
Baseline
L1_20%
L1_30%
Network Slimming
Taylor
Hernia
Pneumonia
Fibrosis
Edema
Emphysema
Cardiomegaly
ural_Thickening
Pneumothorax
Consolidation
Mass
Nodule
Atelectasis
Effusion
Infiltration

Pruning as Regularization

- na wykresie Params vs AUC widoczny jest peak przy 20-35% pruningu
- umiarkowany pruning poprawia generalizację (AUC rośnie)
- wynik jest zgodny z literaturą (Liu et al. (2019), "Rethinking the Value of Network Pruning") - usunięcie nie tylko nie pogarsza jakości modelu, ale w niektórych przypadkach może prowadzić do poprawy zdolności generalizacji



Wpływ na liczbę parametrów



A co z rare classes?

Method	Rare_Classes_Drop	Common_Classes_Drop	Overall_Drop
L1 30% Pruning	-0.0159	-0.0040	-0.0117
Network Slimming	-0.0007	0.0034	0.0008
L1 20% Pruning	0.0092	0.0051	0.0078
Taylor Pruning	0.0161	0.0005	0.0105

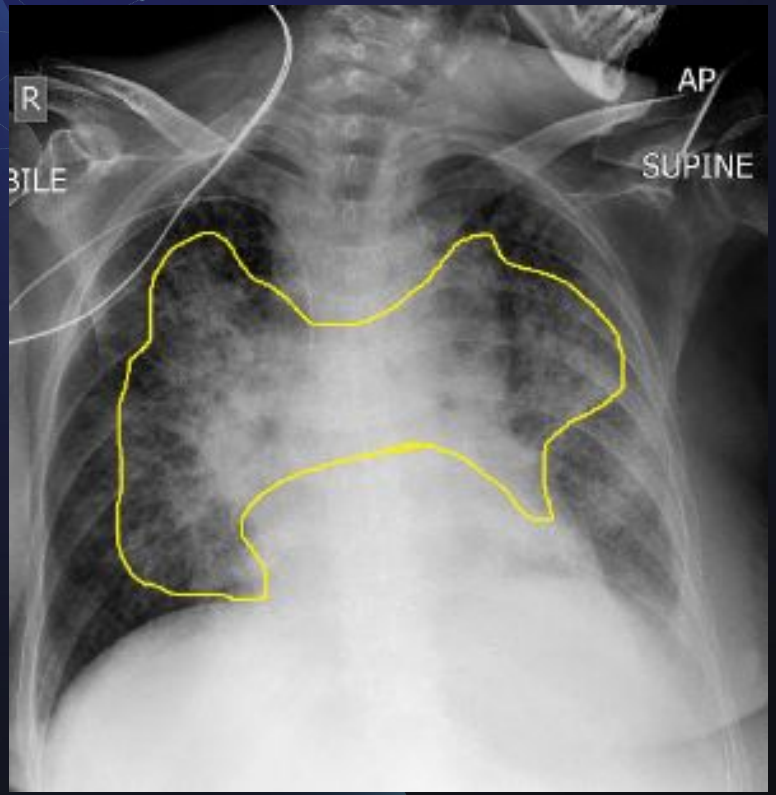
*”Long-Tailed Classification of Thorax Diseases on Chest X-Ray: A New Benchmark Study” (Holste, Wang, 2022)

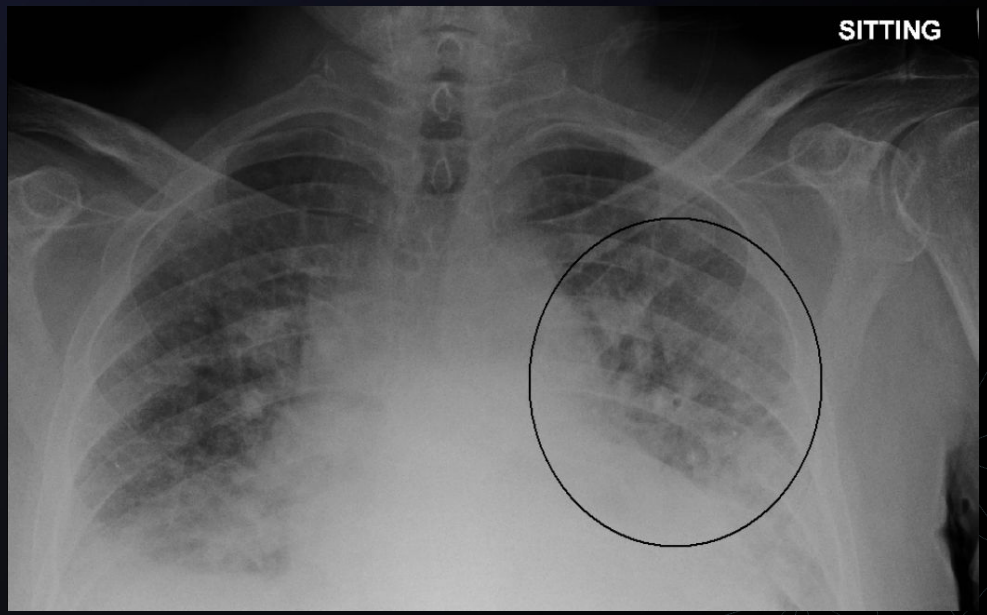
Specific rare classes

<0 -> Pneumonia, Consolidation, Hernia, Edema, Cardiomegaly, Pleural_Thickening
>0 -> Emphysema, Fibrosis

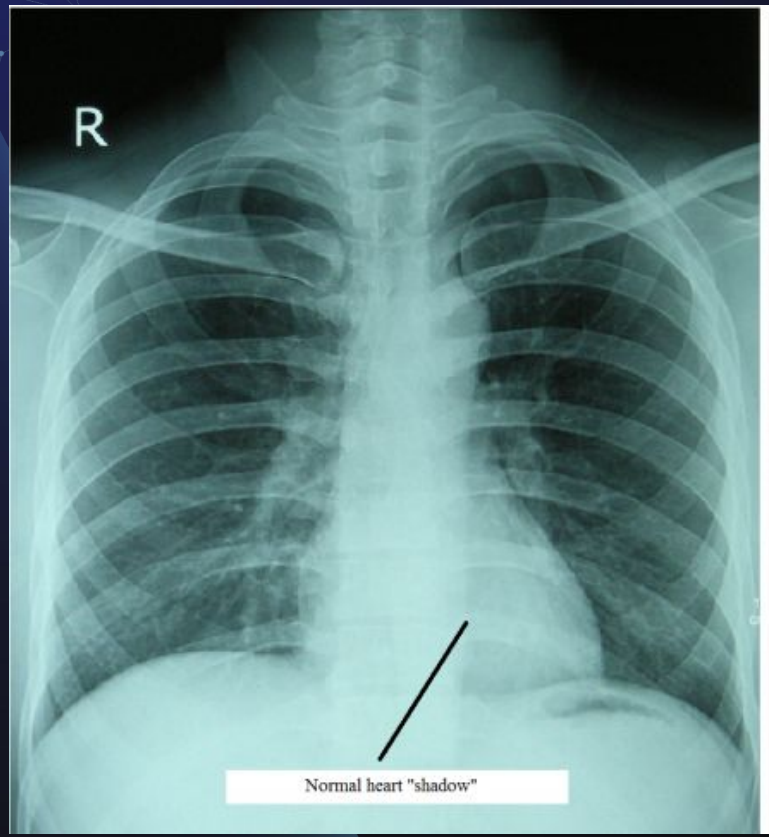
Niektóre z tych patologii są rzadkie statystycznie, ale ich obraz radiologiczny jest stosunkowo **charakterystyczny**.

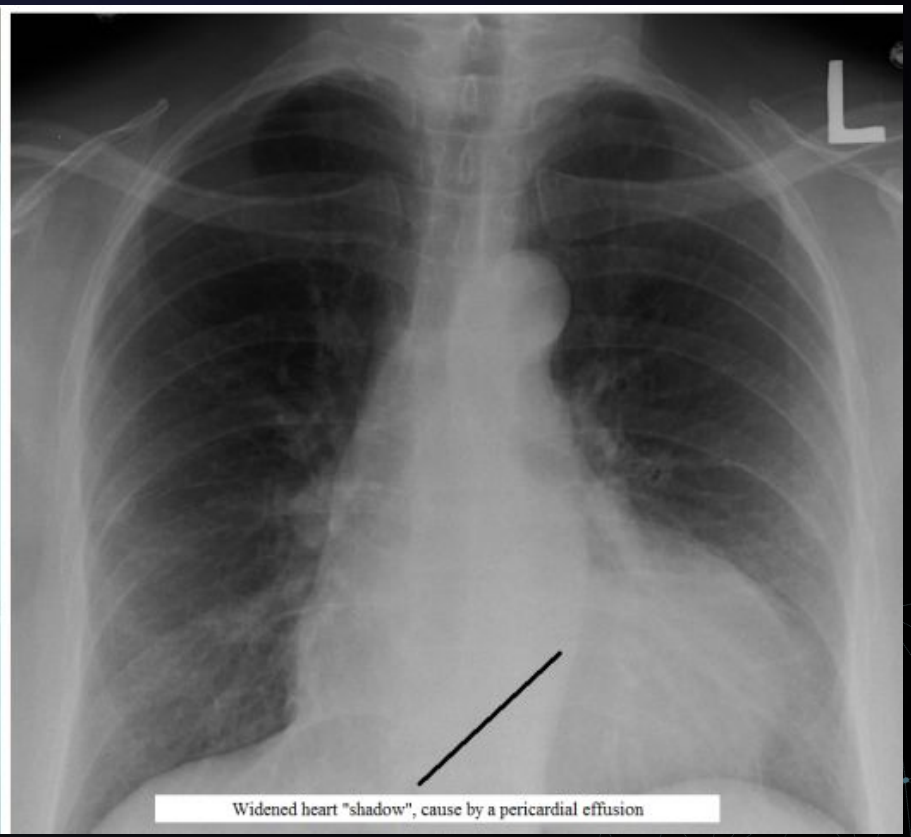
Edema





Cardiomegaly





Skala kliniczna

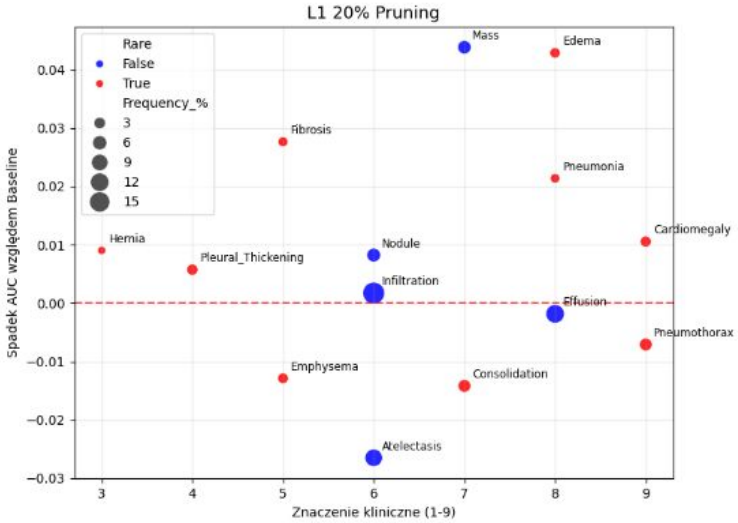
9–8: Cardiomegaly, Pneumothorax, Edema, Pneumonia

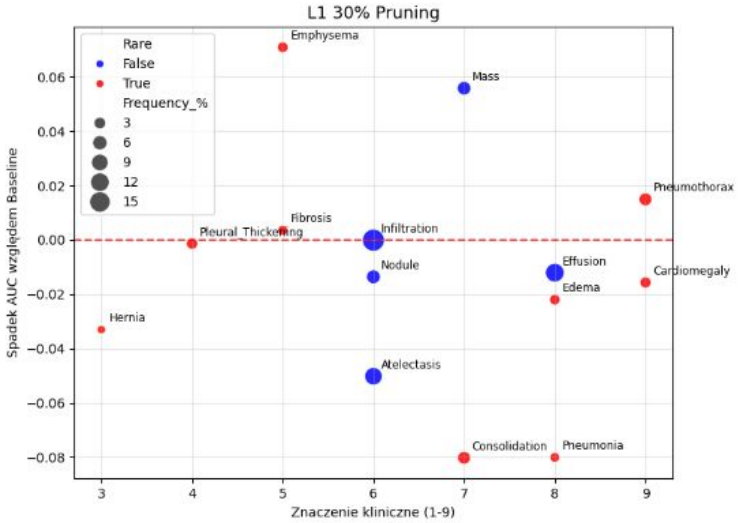
7–6: Consolidation, Mass, Effusion, Atelectasis

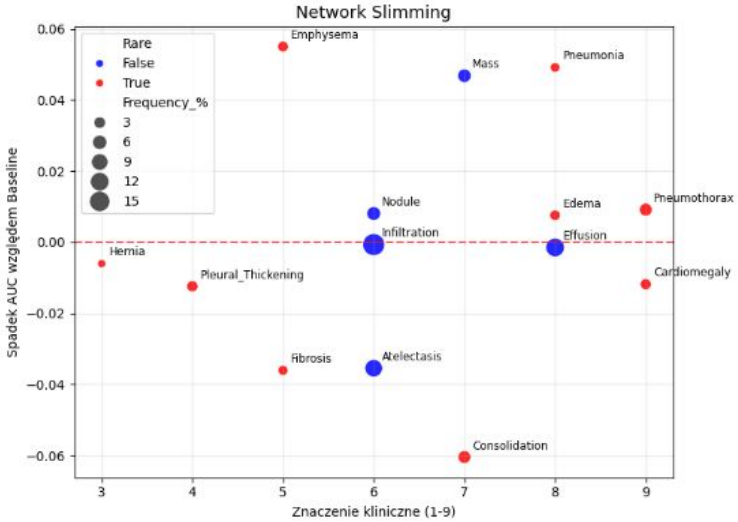
5–3: Emphysema, Fibrosis, Hernia

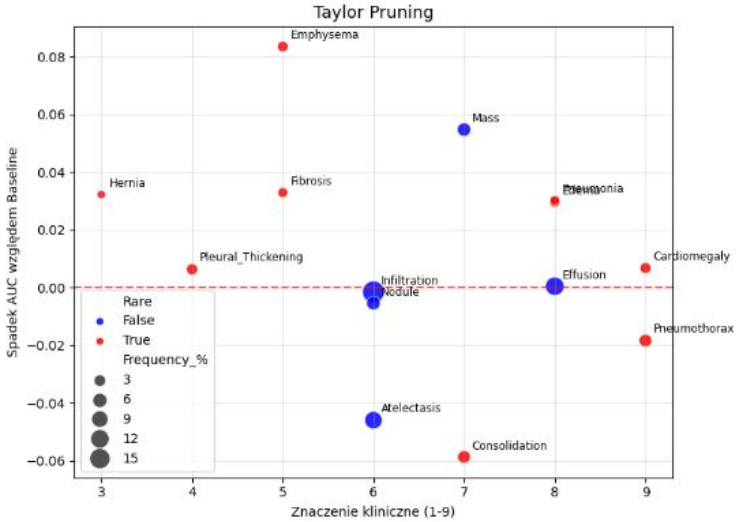


Wpływ pruningu z uwzgl. kontekstu klinicznego









Co wyniosłam z projektu?

- Techniki strukturalnego pruningu (L1, Network Slimming, Taylor Importance)
- Budowanie pipelineów treningowych (AMP + GradScaler, atomic checkpointing, resume training)
- Praca z danymi medycznymi: patient-level split, ważona strata, analiza per-class + kontekst kliniczny
- Analiza trade-offów: kompresja vs jakość vs znaczenie kliniczne

- Umiarkowany pruning pozwala na znaczną redukcję rozmiaru i czasu inferencji modelu przy minimalnej utracie jakości diagnostycznej
- Klasy rzadkie są dość wrażliwe, jednak nie zawsze wynik jest analogiczny do klas zwykłych
- Pruning działa jak implicit regularization - szczególnie korzystny na niezbalansowanych danych medycznych
- W medycynie najważniejsze jest zachowanie jakości na kluczowych, rzadkich patologiach